

Pràctica Bloc III: Aerolínies i Satisfacció

11-XII-2025

Objectiu

L'objectiu d'aquest exercici avaluable és aplicar els conceptes i tècniques d'aprenentatge automàtic apreses durant el curs.

- Aquesta pràctica s'ha d'entregar no més tard del dia de l'avaluació complementària, **14 de gener de 2026 a les 23:59**.
- El resultat de la pràctica serà un document **Notebook** (.ipynb) a on s'ha de combinar tant el codi Python per resoldre el problema com les respectives explicacions en Markdown. També s'ha d'entregar una versió PDF d'aquest.
- La pràctica s'ha de realitzar en parella.
- Únicament es corregiran les pràctiques dels alumnes que hagin dut terme una entrevista personalitzada posterior a l'entrega.

Materials

La pràctica es realitzarà amb Python emprant l'entorn de l'assignatura. És necessari l'ús de les llibreries **Scikit-learn**, **Pandas**, **Matplotlib** i **Seaborn**. El conjunt de dades a utilitzar és el *Airline Passenger Satisfaction Dataset*.

Descripció del problema

Les aerolínies modernes recullen grans quantitats de dades sobre els seus clients per intentar millorar la seva experiència i fidelitat. En aquesta pràctica, treballarem amb un conjunt de dades¹ que conté informació sobre passatgers d'una aerolínia nord-americana.

Per llegir el conjunt de dades podeu emprar el codi següent:

¹<https://www.kaggle.com/datasets/teejmahal20/airline-passenger-satisfaction>

```
1 import pandas as pd
2
3 df = pd.read_csv("airline_passenger_satisfaction.csv")
```

Aquest conjunt de dades conté informació demogràfica dels passatgers (gènere, edat, tipus de client), detalls del vol (classe, distància de vol) i, el més important, puntuacions de satisfacció (del 0 al 5) en diferents serveis com el Wifi a bord, la comoditat del seient, el menjar, etc. La variable objectiu final és `satisfaction`, que indica si el passatger està "Satisfied" o "Neutral or Dissatisfied".

Treball a fer

La tasca a realitzar en aquesta pràctica consisteix a comparar el rendiment de diversos models d'aprenentatge automàtic utilitzant el conjunt de dades proporcionat. Els models seleccionats per a aquesta comparació són els següents: el Perceptró, la Regressió Logística, les Màquines de Vectors de Suport (SVM per les seves sigles en anglès), els Arbres de Decisió i els Boscos Aleatoris. Tots aquests models estan disponibles a la llibreria `Scikit-learn`².

Passos a seguir

La comparació ha d'incloure els següents elements clau:

1. **Preprocessament.** Normalització de dades necessària; tractament de variables categòriques; tractament de valors faltant (NaNs)
2. **Anàlisi exploratòria de dades (EDA).** Abans d'entrenar els models, serà imprescindible dur a terme una anàlisi detallada de les dades. Es recomana l'ús d'algoritmes de clústering i l'anàlisi dels clústers resultants: quines característiques defineixen cada grup? (Ex: Els viatgers de negocis que volen distàncies llargues s'agrupen junts?).
3. **Selecció dels millors hiperparàmetres.** Per tal d'obtenir el millor rendiment possible de cada model, s'hauran d'ajustar els seus hiperparàmetres emprant les tècniques vistes a classe. A més s'ha de justificar l'ús dels hiperparàmetres a partir del seu efecte al model. Com a mínim per a cada model s'han de seleccionar dos hiperparàmetres amb al manco tres valors diferents.
4. **Ús correcte de les mesures d'avaluació.** Es valorarà l'aplicació adequada de mètriques per avaluar el rendiment dels models. A més, s'ha de justificar la selecció de cada mètrica segons el problema que es vol resoldre.

²<https://scikit-learn.org/stable/>

5. **Discussió crítica dels resultats.** Els resultats obtinguts per cada model han de ser analitzats i comparats de manera detallada. Això inclou:

- Explicar per què certs models poden tenir un rendiment superior o inferior en aquest conjunt de dades.
- Identificar possibles fonts de biaix o errors en les prediccions.
- Utilització de taules per dur a terme de manera simple i directe l'estudi comparatiu.
- Ús de gràfics i tècniques de visualització per comparar els resultats i millorar l'anàlisi elaborada.

Criteris de Valoració

Les decisions preses al llarg de tot el procés han d'estar correctament justificades en el document de lliurament. Per exemple, si s'opta per una tècnica de selecció d'hiperparàmetres o si es decideix no incloure determinades variables en el model final, aquestes decisions han de ser clarament explicades.

És important tenir en compte que el que es valora no és el resultat obtingut (la mètrica) sinó el procés realitzat.

En resum, aquesta pràctica no només pretén ser una comparació del rendiment tècnic dels models, sinó també fomentar una anàlisi reflexiva i crítica que permeti entendre millor com i per què aquests models funcionen en el context del conjunt de dades proporcionat.

Condicions

És condició *sine qua non* per a la correcció de la pràctica que aquesta funcioni a l'ordinador del professor, l'entrega del *Notebook* en format `.ipynb`, la seva versió en PDF i la realització de l'entrevista.