

Memòria de la Pràctica 2

Aprenentatge per reforç

Serafi Nebot Ginard
Jaume Galmés Ramis

21722 - Intel·ligència Artificial
Grau d'Enginyeria Informàtica
Curs 2025/2026

Índex

1	Introducció	1
2	Disseny algorismes	2
2.1	Genètic	2
2.2	Programació dinàmica	3
2.3	Monte Carlo	3
2.4	SARSA	3
2.5	Q-learning	3
3	Estudi dels paràmetres	4
3.1	Algorismes d'aprenentatge	4
4	Conclusió	8

Introducció

...

Investigant diferents algorismes de RL hem trobat el Average Q-learning, que és una extensió del Q-learning que hem vist a classe. Ens ha semblat interessant i l'hem inclòs al projecte.

Disseny algorismes

2.1 Genètic

Individu

Un individu representa una política $\pi_i(s_t) \in A$ on a cada possible estat se li assigna una acció. La població d'individus conté, per a cada generació, n individus. Per a la primera generació, els gens de tots els individus (cromosomes) s'inicialitzen de forma completament aleatòria.

Funció *fitness*

La funció fitness és la tasa d'èxit de l'individu. Al ser un entorn estocàstic s'evalua la política durant 100 episodis i es calcula el promig de vegades que s'ha arribat al destí.

Pel cas particular del *Frozen Lake* totes les recompenses són 0 excepte quan s'arriba al destí, per tant, la funció *fitness* és equivalent al promig de recompenses totals obtingudes al llarg de tots els episodis.

$$fitness(\pi_i) = \frac{1}{100} \sum_{j=1}^{100} \sum_{t=1}^T R_t^j$$

On R_t^j és la recompensa del període t de l'episodi j .

Elitisme o *Culling*

Abans de generar la nova generació es seleccionen els $l = \lceil c \cdot n \rceil$ millors individus que passen directament a la nova generació (la resta es descarten), on $c \in [0, 1]$ és la tasa de *culling*. Una $c > 0$ ens garanteix que no es perdin els millors individus amb el pas de les generacions.

Selecció

De tots els individus de cada generació, n en total, només es seleccionen els $k = \lceil \beta \cdot n \rceil$ millors, on $\beta \in (0, 1]$ és el paràmetre de pressió de selecció. D'aquesta forma, β , ens permet escollir quin percentatge de la millor part de la població volem emprar per a generar la pròxima generació.

Mutació

Després de generar cada individu hi ha una petita probabilitat m de mutar-lo de forma

aleatòria. Per fer-ho, per a cada gen de l'individu es genera un nombre aleatori $p \in [0, 1]$ i es genera un gen aleatori si $p < m$ i l'original si $p \geq m$.

$$\begin{cases} \text{original} & \text{si } p \geq m \\ \text{aleatori} & \text{si } p < m \end{cases}$$

2.2 Programació dinàmica

2.3 Monte Carlo

2.4 SARSA

2.5 Q-learning

Estudi dels paràmetres

A continuació es mostra com diferents variacions dels paràmetres de cada un dels models afecta als resultats.

Per a cada configuració dels paràmetres, cada un dels algorismes primer passa per a la fase d'entrenament de n episodis i després s'evalua la política resultant amb 1000 episodis per a contrarestar el factor estocàstic de l'entorn.

Per a mantenir el document breu, les úniques mètriques que comparam són el nombre promig de passes (*steps*) que es tarda per a cada episodi i el promig de vegades que s'ha arribat al destí, anomenat *sr* (*Success Rate*).

3.1 Algorismes d'aprenentatge

Per a *Monte Carlo*, *SARSA* i *Q-learning* tenim els següent paràmetres:

- $dr = 0.99$: *Discount Rate* o *gamma* als apunts, és el factor de descompte per a la recompensa esperada per a cada passa del mateix episodi.
- $er = 1.00$: *Exploration Rate* o *epsilon* als apunts, és el factor d'exploració per a una política *epsilon-greedy*.
- $er_min = 0.01$: *Exploration Rate Minimum* és el mínim permès del valor er .
- $er_decay = 0.9995$: *Exploration Rate Decay* és el factor de descens del paràmetre er . A cada iteració del bucle d'entrenament es decrementa el factor d'exploració: $er = \min\{er_min, er \cdot er_decay\}$.

Per a *SARSA* i *Q-learning* tenim $lr = 0.01$ (*Learning Rate* o *alpha* als apunts) que és el factor d'aprenentatge.

Amb aquests valors per defecte dels paràmetres obtenim els següents resultats que ens serviran per a comparar amb el pròxim apartat:

Monte Carlo		SARSA		Q-learning	
steps	sr	steps	sr	steps	sr
41.3870	0.7030	44.3640	0.7320	44.1830	0.7300

A continuació es mostren els resultats de totes les variacions de cada un dels paràmetres:

	Monte Carlo		SARSA		Q-learning	
dr	steps	sr	steps	sr	steps	sr
0.10	15.3360	0.2110	9.2340	0.0620	9.2420	0.1120
0.20	9.2610	0.1030	8.5430	0.1010	7.3150	0.0470
0.30	6.9370	0.1010	16.0000	0.1760	6.2980	0.0600
0.40	8.4560	0.1020	20.9020	0.1790	14.2070	0.1560
0.50	10.0620	0.1180	14.5330	0.1570	21.9130	0.2800
0.60	6.1020	0.0750	33.7380	0.5140	22.0330	0.2630
0.70	35.7620	0.5640	16.2900	0.2180	30.5880	0.4590
0.80	18.2380	0.2030	26.8600	0.3900	27.9760	0.4460
0.90	8.5550	0.0670	41.5030	0.6280	41.8290	0.7180
1.00	26.0580	0.3240	44.7220	0.7600	100.000	0.0000

SARSA i Q-learning es comporten de forma molt similar i prefereixen un dr molt proper a 1, exceptuant el cas $dr = 1.00$ on Q-learning es veu molt afectat i no arriba cap vegada al destí en totes les 1000 iteracions de prova.

Monte Carlo, per altra banda, sembla ser molt sensible a petits canvis del paràmetre i , per aquesta prova limitada, no podem veure un patró clar. A les proves que hem fet durant el desenvolupament sabem que el valor per defecte que hem triat genera resultats variats (0.30 i 0.70 de *Survival Rate*, que és el que veiem a la taula amb el valor 1.00), dependent de la inicilització de la semilla del generador de nombres aleatoris.

	Monte Carlo		SARSA		Q-learning	
er	steps	sr	steps	sr	steps	sr
0.10	24.7740	0.2420	43.8000	0.7430	46.1800	0.7360
0.20	27.6060	0.1950	45.8280	0.7440	43.3920	0.7630
0.30	38.0640	0.6740	43.5510	0.7550	45.3150	0.7380
0.40	30.1160	0.5200	45.4450	0.7440	45.6250	0.7290
0.50	40.1320	0.7390	43.4110	0.7570	45.3650	0.7710
0.60	30.0940	0.2350	43.7320	0.7640	45.3130	0.6970
0.70	40.6120	0.7150	43.8760	0.7380	44.4060	0.7330
0.80	40.6070	0.7340	44.9870	0.7380	44.1360	0.7530
0.90	41.1670	0.7310	42.6170	0.7520	45.2820	0.7320
1.00	41.2560	0.7030	45.6850	0.7440	45.0200	0.7330

SARSA i Q-learning no es veuen afectats pel valor de er . Això és degut a una característica particular de la nostra implementació dels algorismes d'aprenentatge.

Monte Carlo necessita una exploració major a l'inici de l'entrenament per a poder trobar una solució òptima.

	Monte Carlo		SARSA		Q-learning	
<i>er_min</i>	steps	sr	steps	sr	steps	sr
0.10	6.3470	0.0660	40.7290	0.7200	45.1450	0.7380
0.20	10.7840	0.0900	39.1340	0.7460	45.5910	0.7680
0.30	27.8450	0.2690	41.3910	0.7160	44.2060	0.7570
0.40	6.7520	0.0980	41.9450	0.7300	43.6270	0.7450
0.50	12.3250	0.1870	39.7820	0.6890	43.4790	0.7480
0.60	11.2170	0.1170	42.2630	0.7120	45.9040	0.7170
0.70	9.0570	0.1260	23.1390	0.2830	44.0580	0.7150
0.80	32.8600	0.5210	39.8010	0.7070	44.8900	0.7240
0.90	24.2700	0.3700	36.0990	0.6080	44.2430	0.7470
1.00	34.0410	0.4590	24.2430	0.3300	45.1970	0.7510

Q-learning no es veu afectat en absolut i SARSA negativament per a valors alts de *er_min*. Per tant, una exploració alta al final de la fase d'entrenament perjudica molt a SARSA probablement degut a que per a calcular la correcció de la recompensa esperada SARSA utilitza l'acció realitzada i Q-learning sempre utilitza la millor, ignorant així el factor aleatori.

Monte Carlo, per altra banda, prefereix una exploració alta mantinguda, però segons els paràmetres per defecte que hem triat sabem que millora encara més.

	Monte Carlo		SARSA		Q-learning	
<i>er_decay</i>	steps	sr	steps	sr	steps	sr
0.10	8.0950	0.0810	45.0600	0.7450	44.2680	0.7310
0.20	24.4520	0.2640	44.3870	0.7490	44.5310	0.7350
0.30	27.6170	0.4670	44.1920	0.7530	45.1240	0.7410
0.40	30.0460	0.2070	44.2520	0.7570	44.5730	0.7040
0.50	10.5710	0.0960	43.6780	0.7320	43.7620	0.7330
0.60	24.0870	0.1480	43.4670	0.7380	43.2330	0.7310
0.70	13.6050	0.1610	45.8600	0.7550	45.3060	0.7320
0.80	38.2980	0.6750	46.0460	0.7290	42.9090	0.7590
0.90	9.6760	0.0970	44.9890	0.7380	44.9960	0.7310
1.00	39.8340	0.6960	22.6820	0.3380	44.5930	0.7470

Una altre vegada, Q-learning no es veu afectat en absolut i SARSA només quan es manté el factor d'exploració alt (el mateix per a *er_decay* = 1.0) durant tot l'entrenament.

En aquest cas, Monte Carlo obté molt bons resultats quan *er_decay* és molt proper a 1.0, consistent amb els resultats que hem obtingut amb el valor per defecte.

lr	SARSA		Q-learning	
	steps	sr	steps	sr
0.10	44.607	0.74	44.711	0.721
0.20	44.706	0.644	45.731	0.745
0.30	44.441	0.72	45.358	0.732
0.40	46.921	0.638	45.021	0.725
0.50	46.462	0.734	43.33	0.734
0.60	28.884	0.244	44.917	0.735
0.70	62.305	0.561	42.406	0.756
0.80	61.438	0.573	44.273	0.758
0.90	8.856	0.102	45.38	0.744
1.00	7.832	0.024	7.837	0.022

Podem veure que SARSA és molt més sensible al *Learning Rate* que Q-learning, ja que aquest darrer es manté igual al llarg de totes les combinacions.

Per a valors molt grans de lr ambdós tenen resultats molt pobres, sobretot quan son molt propers a 1. Això té sentit perquè significa que per a cada actualització de la política s'està corregint un 100% de l'error, es a dir, s'estàn fent salts molt grans i no s'arriba a la solució òptima (s'arriba a un màxim local enlloc d'un màxim global).

Conclusió

Pràctica Bloc I

Intel·ligència Artificial

Aprenentatge per reforç

Serafi Nebot Ginard

Jaume Galmés Ramis

Grau d'Enginyeria Informàtica
Curs 2025/2026