

Memòria de la Pràctica 2

Aprenentatge per reforç

Serafi Nebot Ginard
Jaume Galmés Ramis

21722 - Intel·ligència Artificial
Grau d'Enginyeria Informàtica
Curs 2025/2026

Índex

1	Introducció	1
2	Disseny algorismes	2
2.1	Algorismes Aprenentatge	2
2.1.1	Monte Carlo	3
2.1.2	SARSA	4
2.1.3	Q-learning	4
2.2	Algorismes Cerca	5
2.2.1	Genètic	5
2.2.2	Programació dinàmica	8
3	Estudi dels paràmetres	9
3.1	Algorismes d'aprenentatge	9
3.2	Algorismes de cerca	13
3.2.1	Genètic	13
3.2.2	Programació dinàmica	15
4	Anàlisi rendiment	17
5	Anàlisi polítiques	20
6	Conclusió	23
7	Intel·ligències Artificials Generatives	24

Introducció

En aquesta pràctica hem explorat i implementat diversos algorismes d'aprenentatge per reforç i de cerca a l'entorn de *Frozen Lake* de Gymnasium amb l'opció *slippery* activada.

A n'aquest entorn un agent ha de travessar un llac gelat evitant forats per arribar a una meta. L'opció *slippery* afegeix un problema estocàstic que provoca que les accions tenguin només un 33 % de probabilitat d'executar-se correctament i la resta facin lliscar a l'agent en direccions paral·leles.

L'objectiu principal ha estat comparar el comportament i la sensibilitat als paràmetres dels algorismes implementats:

Algorismes d'aprenentatge

- Monte Carlo
- SARSA
- Q-learning

Algorismes de cerca

- Programació Dinàmica
- Genètic

Hem analitzat com influeixen paràmetres com el factor de descompte γ , la taxa d'exploració ε i el seu decaïment, la taxa d'aprenentatge α i, en el cas dels algorismes evolutius, la mida de la població, la pressió de selecció, la taxa de mutació i l'elitisme. També hem estudiat l'impacte d'una decisió de disseny aparentment menor — l'ús d'un tie-break aleatori quan diverses accions tenen el mateix valor Q — que ha resultat ser clau per evitar biaixos greus en l'exploració inicial.

A més, hem comparat el rendiment durant l'entrenament, l'evolució de la taxa d'èxit (*Survival Rate*) i la qualitat de les polítiques finals, observant comportaments inesperats (polítiques que semblen contraintuïtives però que són òptimes donat el factor estocàstic).

Disseny algorismes

2.1 Algorismes Aprenentatge

Tots els algorismes d'aprenentatge per reforç implementats són mètodes que estimen la funció valor-acció $Q : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ i deriven la política mitjançant una regla ε -greedy amb *tie-break* aleatori.

Un aspecte clau de la nostra implementació és la selecció de l'acció en un estat s :

- La taula Q s'inicialitza a zero per a tots els parells estat-acció: $Q(s, a) \leftarrow 0 \quad \forall s \in \mathcal{S}, \forall a \in \mathcal{A}$
- Durant l'entrenament: política ε -greedy amb decaïment exponencial de ε i mínim $\varepsilon_{\min} = 0.01$.
- En cas d'empat (diverses accions amb el mateix valor $Q(s, \cdot)$ màxim), s'escull una acció uniformement aleatòria entre les candidates:

$$a' \sim \text{Unif}(\arg \max_a Q(s, a))$$

Aquest *tie-break* aleatori elimina el biaix sistemàtic que produeix $\arg \max$ de NumPy (sempre retorna el primer índex màxim) i, com es mostra a la secció d'anàlisi de paràmetres, resulta crític per aconseguir una exploració equilibrada en les primeres fases de l'entrenament.

D'aquesta forma queda definida l'elecció de la següent acció durant l'etapa d'entrenament:

$$a' \sim \begin{cases} \text{Unif}(\arg \max_a Q(s, a)) & \text{amb probabilitat } 1 - \epsilon \\ \text{Unif}(\mathcal{A}(s)) & \text{amb probabilitat } \epsilon \end{cases}$$

2.1.1 Monte Carlo

L'algorisme de Monte Carlo és un mètode d'aprenentatge per reforç basat en episodis, útil quan es poden generar seqüències completes fins a l'estat terminal. A diferència d'altres mètodes, estima directament els retorns observats per aprendre valors i polítiques sense necessitat de conèixer la dinàmica de l'entorn.

Estructura d'un episodi

Un episodi comença en un estat inicial S_0 i finalitza en un estat terminal S_T , amb la següent estructura general: $(S_0, A_0, R_1), (S_1, A_1, R_2), \dots, (S_{T-1}, A_{T-1}, R_T), S_T$, on S_t és l'estat de l'agent al pas t , A_t és l'acció presa en aquest estat i R_{t+1} és la recompensa obtinguda després de realitzar l'acció A_t .

Un cop generat l'episodi es recorr la seqüència començant per l'estat terminal, aquí és on obtenim la funció acció-valor i consegüentment la nova política.

Funció de recompensa acumulada

Cada episodi té una recompensa acumulada que anomenam G . La funció de retorn d'un episodi a partir de la passa t es calcula com:

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k R_{t+k+1}$$

on $\gamma \in [0, 1]$ és el factor de descompte, R_{t+k+1} és la recompensa al pas $t + k + 1$, T és l'últim pas de l'episodi i k recorre les recompenses futures des del pas t fins a $T - 1$.

Funció d'acció-valor i política

La funció acció-valor es calcula com la mitja dels retorns obtinguts a l'estat-acció en qüestió, és a dir:

$$Q(s, a) = \frac{1}{N(s, a)} \sum_{i=1}^{N(s, a)} G_i(s, a)$$

on $N(s, a)$ és el nombre de vegades que s'ha visitat la parella (s, a) , i $G_i(s, a)$ és el retorn de l'episodi on es va visitar (s, a) .

2.1.2 SARSA

SARSA és un algorisme *on-policy* d'aprenentatge per reforç que estima la funció valor-acció $Q(s, a)$ seguint la mateixa política que s'està millorant.

L'actualització de la taula Q es realitza al final de cada pas dins d'un episodi, emprant el quintuple $(S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1})$ d'on prové el seu nom (*State-Action-Reward-State-Action*):

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

on:

- $\alpha \in (0, 1]$ és la taxa d'aprenentatge.
- $\gamma \in [0, 1]$ és el factor de descompte.
- A_{t+1} s'obté aplicant la política actual π a l'estat S_{t+1} , seguint una política ε -greedy.

Com que l'actualització depèn de l'acció realment escollida en el següent estat (A_{t+1}), SARSA tendeix a ser més conservador.

2.1.3 Q-learning

Q-learning és un algorisme *off-policy* de control que estima directament la funció valor-acció òptima $Q^*(s, a)$ sense necessitat de seguir la política actual durant l'aprenentatge.

L'actualització es realitza després de cada transició $(S_t, A_t, R_{t+1}, S_{t+1})$ emprant el valor de la millor acció possible en l'estat següent:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_{a'} Q(S_{t+1}, a') - Q(S_t, A_t) \right]$$

Amb els mateixos paràmetres α i γ que en SARSA. La diferència clau és l'ús de $\max_{a'} Q(S_{t+1}, a')$ en lloc de $Q(S_{t+1}, A_{t+1})$, cosa que fa que Q-learning sigui optimista i convergeixi a la política òptima fins i tot quan la política de comportament (la que genera les experiències) sigui completament aleatòria'.

2.2 Algorismes Cerca

2.2.1 Genètic

L'algorisme genètic és un mètode de cerca inspirat en l'evolució biològica que treballa directament sobre l'espai de polítiques $\pi : S \rightarrow A$ sense estimar cap funció valor. Cada individu de la població representa una política completa (un vector de 16 enters, un per cada estat del mapa 4×4).

El procés evolutiu és el següent:

1. S'inicialitza una població de polítiques aleatòries.
2. S'avalua el *fitness* de cada individu executant 100 episodis i calculant la taxa d'èxit.
3. Els millors individus passen directament a la següent generació (elitisme).
4. Es seleccionen els pares a partir dels millors individus (major valor *fitness*) de la població.
5. Es generen els fills per creuament aleatori i mutació gen a gen amb probabilitat *mutation_rate*.
6. Es repeteix el procés durant un nombre fix de generacions.

Individu

Cada individu de la població representa una política completa $\pi : \mathcal{S} \rightarrow \mathcal{A}$.

Com que l'espai d'estats té només 16 elements (tauler 4×4), codificam la política com un vector de 16 enters:

$$\pi = (a_0, a_1, \dots, a_{15}) \in \{0, 1, 2, 3\}^{16}$$

on cada $a_i \in \{0 = \textit{left}, 1 = \textit{down}, 2 = \textit{right}, 3 = \textit{up}\}$ indica l'acció que l'individu executa de manera fixa quan es troba a l'estat corresponent s_i .

Aquesta representació directa sobre l'espai de polítiques (en lloc de sobre taules Q) té diverses avantatges:

- Mida de memòria mínima (16 enters per individu).
- Operacions de creuament i mutació molt senzilles i ràpides.
- L'avaluació del fitness es tradueix directament en la qualitat de la política final.

La població consta de *population_size* individus d'aquest tipus. La primera generació s'inicialitza amb polítiques completament aleatòries (cada gen a_i s'escull uniformement entre les 4 accions).

Funció *fitness*

El *fitness* d'una política π es defineix com la probabilitat estimada d'arribar a l'estat objectiu G quan es segueix π des de l'estat inicial s_0 . Com que l'entorn és estocàstic, s'estima mitjançant l'èxit promig sobre $N = 100$ episodis independents:

$$fitness(\pi) = \frac{1}{N} \sum_{k=1}^N \mathbf{1}\{\text{episodi } k \text{ arriba a } G\}$$

on $\mathbf{1}\{\cdot\}$ és la funció indicadora. Com que a *Frozen Lake* l'única recompensa no nul·la és +1 en arribar a G i 0 en qualsevol altre cas, aquesta expressió és equivalent a la recompensa total promig per episodi:

$$fitness(\pi) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^T R_t \right] \approx \frac{1}{N} \sum_{k=1}^N G^{(k)}$$

on $G^{(k)} \in \{0, 1\}$ indica si l'episodi k ha acabat amb èxit. A la pràctica, *fitness*(π) coincideix amb el *Success Rate* utilitzat a la resta de la memòria.

Elitisme o *Culling*

Per garantir la preservació dels millors individus trobats al llarg de l'evolució, s'aplica una estratègia d'elitisme. Abans de generar la nova generació, es copien directament els $\lceil culling_rate \cdot population_size \rceil$ individus amb major *fitness* de la generació actual a la següent.

Matemàticament, si ordenam la població de la generació g segons el seu *fitness* de forma decreixent:

$$P^{(g)} = \{\pi_1^{(g)}, \pi_2^{(g)}, \dots, \pi_{|P|}^{(g)}\}, \quad fitness(\pi_1^{(g)}) \geq fitness(\pi_2^{(g)}) \geq \dots \geq fitness(\pi_{|P|}^{(g)})$$

llavors l'elit de la generació g és:

$$E^{(g)} = \{\pi_1^{(g)}, \pi_2^{(g)}, \dots, \pi_k^{(g)}\}, \quad k = \lceil culling_rate \cdot population_size \rceil$$

Aquests k individus passen inalterats a la generació $g + 1$. La resta de la població es genera mitjançant selecció, creuament i mutació a partir dels pares seleccionats.

Aquest mecanisme assegura que el millor *fitness* global mai disminueixi entre generacions.

Selecció

La selecció determina quins individus de la generació actual actuen com a pares per generar la pròxima generació. S'utilitza una selecció per truncament controlada pel paràmetre $selection_pressure \in (0, 1]$.

Primer, s'ordena la població de la generació g segons el seu *fitness* de forma decreixent:

$$P^{(g)} = \{\pi_1^{(g)}, \pi_2^{(g)}, \dots, \pi_{|P|}^{(g)}\}, \quad fitness(\pi_1^{(g)}) \geq fitness(\pi_2^{(g)}) \geq \dots \geq fitness(\pi_{|P|}^{(g)})$$

A continuació, es seleccionen els *parents_size* millors individus com a conjunt de pares:

$$parents_size = \lceil selection_pressure \cdot population_size \rceil$$

$$Pares^{(g)} = \{\pi_1^{(g)}, \pi_2^{(g)}, \dots, \pi_{parents_size}^{(g)}\}$$

Aquests pares es fan servir per generar la resta d'individus de la generació següent (excepte els que ja han estat reservats per elitisme).

Mutació

La mutació és l'únic operador que introdueix novetat genètica real a la població i evita la convergència prematura a màxims locals.

Després de generar un fill mitjançant creuament, cada un dels seus 16 gens (accions) es muta de forma independent amb probabilitat $mutation_rate \in [0, 1]$.

$$a'_i = \begin{cases} \text{Unif}(\mathcal{A}) & \text{si } u_i < mutation_rate \\ a_i & \text{en cas contrari} \end{cases}$$

on $u_i \sim \mathcal{U}[0, 1]$ és una variable aleatòria independent per a cada posició $i = 0, \dots, 15$, i $\text{Unif}(\mathcal{A})$ escull una de les 4 accions possibles amb igual probabilitat.

2.2.2 Programació dinàmica

L'algorisme de Programació Dinàmica (DP) actua com un mètode de cerca sobre un model completament conegut de l'entorn. DP no requereix exploració ni aprenentatge a partir de l'experiència, ja que les decisions són sempre *greedy* respecte al model.

En concret, l'algorisme implementat és el de *Value Iteration*, aquest calcula de manera iterativa la funció de valor òptima $V^*(s)$ per a cada estat, i a partir d'aquesta s'extreu la política òptima. La nostra implementació itera fins arribar a un límit establert.

Dinàmica de l'entorn: el diccionari P

El model de l'entorn proporcionat per Gymnasium s'identifica com P. Aquest diccionari defineix completament el procés de decisió de Markov (MDP) i té l'estructura:

$$P[s][a] = \{(p, s', r, d)\}$$

on cada tupla conté la probabilitat p , el nou estat s' , la recompensa r i si l'episodi finalitza d . Així, per a cada estat i acció, P especifica totes les transicions possibles i les seves probabilitats.

Degut a la naturalesa de l'entorn de *Frozen Lake* amb *slippery* activat, la matriu P principalment compta amb tres tuples per cada parell (estat, acció), la probabilitat d'anar cap a la direcció desitjada més les d'anar cap als costats.

Funció de valor

Inicialment, els valors dels estats s'inicialitzen a zero, i després s'actualitzen repetidament aplicant la funció de valor òptima:

$$V(s) \leftarrow \max_a \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V(s')]$$

on $P(s' | s, a)$ és la probabilitat de passar a l'estat s' duent a terme l'acció a a l'estat s ; $R(s, a, s')$ la recompensa de dur a terme la transició en qüestió i $V(s')$ el valor de l'estat següent ponderat pel factor de descompte $\gamma \in [0, 1]$.

Política òptima

Com a mètode *model-based*, *Value Iteration* garanteix obtenir una política òptima en MDPs quan el factor de descompte $\gamma < 1$. Un cop convergeixen els valors, la política òptima s'obté triant per a cada estat l'acció que maximitza la recompensa esperada.

$$\pi^*(s) = \arg \max_a \sum_{s'} P(s'|s, a) [R(s, a, s') + \gamma V^*(s')]$$

Estudi dels paràmetres

A continuació es mostra com diferents variacions dels paràmetres de cada un dels models afecta als resultats.

Per a cada configuració dels paràmetres, cada un dels algorismes primer passa per la fase d'entrenament de n iteracions i després s'avalua la política resultant amb 1000 episodis, per a contrarestar el factor estocàstic de l'entorn.

Per a mantenir el document breu, les úniques mètriques que comparam són el nombre promig de passes (*steps*) que es tarda per a cada episodi i el promig de vegades que s'ha arribat al destí, anomenat *sr* (*Success Rate*).

3.1 Algorismes d'aprenentatge

Per a tota aquesta secció el nombre d'episodis d'entrenament $n = 20000$.

Per a *Monte Carlo*, *SARSA* i *Q-learning* tenim els següent paràmetres:

- $\gamma = 0.99$: és el factor de descompte per a la recompensa esperada per a cada passa del mateix episodi.
- $\varepsilon = 1.00$: és el factor d'exploració per a una política ε -greedy.
- $\varepsilon_{min} = 0.01$: és el mínim permès del valor ε .
- $\varepsilon_{decay} = 0.9995$: és el factor de descens del paràmetre ε . A cada iteració del bucle d'entrenament es decrementa el factor d'exploració: $\varepsilon = \min\{\varepsilon_{min}, \varepsilon \cdot \varepsilon_{decay}\}$.

Per a *SARSA* i *Q-learning* tenim $\alpha = 0.10$ que és el factor d'aprenentatge.

Amb aquests valors per defecte dels paràmetres obtenim els següents resultats que ens serviran per a comparar amb el pròxim apartat on es mostren els resultats de totes les variacions de cada un dels paràmetres:

Monte Carlo		SARSA		Q-learning	
steps	sr	steps	sr	steps	sr
41.3870	0.7030	44.3640	0.7320	44.1830	0.7300

	Monte Carlo		SARSA		Q-learning	
γ	steps	sr	steps	sr	steps	sr
0.10	15.3360	0.2110	9.2340	0.0620	9.2420	0.1120
0.20	9.2610	0.1030	8.5430	0.1010	7.3150	0.0470
0.30	6.9370	0.1010	16.0000	0.1760	6.2980	0.0600
0.40	8.4560	0.1020	20.9020	0.1790	14.2070	0.1560
0.50	10.0620	0.1180	14.5330	0.1570	21.9130	0.2800
0.60	6.1020	0.0750	33.7380	0.5140	22.0330	0.2630
0.70	35.7620	0.5640	16.2900	0.2180	30.5880	0.4590
0.80	18.2380	0.2030	26.8600	0.3900	27.9760	0.4460
0.90	8.5550	0.0670	41.5030	0.6280	41.8290	0.7180
1.00	26.0580	0.3240	44.7220	0.7600	100.000	0.0000

SARSA i Q-learning es comporten de forma molt similar i prefereixen un γ molt proper a 1, exceptuant el cas $\gamma = 1.00$ on Q-learning es veu molt afectat i no arriba cap vegada al destí en totes les 1000 iteracions de prova.


Monte Carlo, per altra banda, sembla ser molt sensible a petits canvis del paràmetre i, per aquesta prova limitada, no podem veure un patró clar. A les proves que hem fet durant el desenvolupament sabem que el valor per defecte que hem triat genera resultats variats (0.30 i 0.70 de *Survival Rate*, que és el que veiem a la taula amb el valor 1.00), dependent de la inicilització de la llavor del generador de nombres aleatoris.

	Monte Carlo		SARSA		Q-learning	
ε	steps	sr	steps	sr	steps	sr
0.10	24.7740	0.2420	43.8000	0.7430	46.1800	0.7360
0.20	27.6060	0.1950	45.8280	0.7440	43.3920	0.7630
0.30	38.0640	0.6740	43.5510	0.7550	45.3150	0.7380
0.40	30.1160	0.5200	45.4450	0.7440	45.6250	0.7290
0.50	40.1320	0.7390	43.4110	0.7570	45.3650	0.7710
0.60	30.0940	0.2350	43.7320	0.7640	45.3130	0.6970
0.70	40.6120	0.7150	43.8760	0.7380	44.4060	0.7330
0.80	40.6070	0.7340	44.9870	0.7380	44.1360	0.7530
0.90	41.1670	0.7310	42.6170	0.7520	45.2820	0.7320
1.00	41.2560	0.7030	45.6850	0.7440	45.0200	0.7330


Monte Carlo necessita una exploració major a l'inici de l'entrenament per a poder trobar una solució òptima.

SARSA i Q-learning no es veuen afectats pel valor de ε . Això és degut a que la nostra implementació d'aquests algorismes utilitza un *tie-break* aleatori. Si tornam a entrenar els algorismes amb $\varepsilon = 0.10$ però activant/desactivant el *tie-break* i graficam la distribució

de les vegades que s'ha escollit cada acció durant la fase d'entrenament tenim (esquerra *tie-break off*, dreta *tie-break on*):



També podem graficar l'evolució de la distribució al llarg de l'entrenament (el primer amb *tie-break off* i el segon amb *tie-break on*):



A simple vista es veu que hi ha una diferència abismal. Quan el *tie-break* està desactivat i l'exploració és molt baixa l'acció *left* està desproporcionadament afavorida. Quan el *tie-break* està activat l'elecció de les accions està molt més distribuïda. La raó perquè encara hi ha una preferència sobre les accions *left* i *up* es discuteix a l'apartat d'Anàlisi de les polítiques.

	Monte Carlo		SARSA		Q-learning	
ε_{min}	steps	sr	steps	sr	steps	sr
0.10	6.3470	0.0660	40.7290	0.7200	45.1450	0.7380
0.20	10.7840	0.0900	39.1340	0.7460	45.5910	0.7680
0.30	27.8450	0.2690	41.3910	0.7160	44.2060	0.7570
0.40	6.7520	0.0980	41.9450	0.7300	43.6270	0.7450
0.50	12.3250	0.1870	39.7820	0.6890	43.4790	0.7480
0.60	11.2170	0.1170	42.2630	0.7120	45.9040	0.7170
0.70	9.0570	0.1260	23.1390	0.2830	44.0580	0.7150
0.80	32.8600	0.5210	39.8010	0.7070	44.8900	0.7240
0.90	24.2700	0.3700	36.0990	0.6080	44.2430	0.7470
1.00	34.0410	0.4590	24.2430	0.3300	45.1970	0.7510

Q-learning no es veu afectat en absolut i SARSA negativament per a valors alts de ε_{min} . Per tant, una exploració alta al final de la fase d'entrenament perjudica molt a SARSA probablement degut a que per a calcular la correcció de la recompensa esperada SARSA utilitza l'acció realitzada i Q-learning sempre utilitza la millor, ignorant així el factor aleatori.

Monte Carlo, per altra banda, prefereix una exploració alta mantinguda, però segons els paràmetres per defecte que hem triat sabem que millora encara més.

	Monte Carlo		SARSA		Q-learning	
ε_{decay}	steps	sr	steps	sr	steps	sr
0.10	8.0950	0.0810	45.0600	0.7450	44.2680	0.7310
0.20	24.4520	0.2640	44.3870	0.7490	44.5310	0.7350
0.30	27.6170	0.4670	44.1920	0.7530	45.1240	0.7410
0.40	30.0460	0.2070	44.2520	0.7570	44.5730	0.7040
0.50	10.5710	0.0960	43.6780	0.7320	43.7620	0.7330
0.60	24.0870	0.1480	43.4670	0.7380	43.2330	0.7310
0.70	13.6050	0.1610	45.8600	0.7550	45.3060	0.7320
0.80	38.2980	0.6750	46.0460	0.7290	42.9090	0.7590
0.90	9.6760	0.0970	44.9890	0.7380	44.9960	0.7310
1.00	39.8340	0.6960	22.6820	0.3380	44.5930	0.7470

Una altre vegada, Q-learning no es veu afectat en absolut i SARSA només quan es manté el factor d'exploració alt (el mateix per a $\varepsilon_{decay} = 1.0$) durant tot l'entrenament.

En aquest cas, Monte Carlo obté molt bons resultats quan ε_{decay} és molt proper a 1.0, consistent amb els resultats que hem obtingut amb el valor per defecte.

	SARSA		Q-learning	
α	steps	sr	steps	sr
0.10	44.607	0.74	44.711	0.721
0.20	44.706	0.644	45.731	0.745
0.30	44.441	0.72	45.358	0.732
0.40	46.921	0.638	45.021	0.725
0.50	46.462	0.734	43.33	0.734
0.60	28.884	0.244	44.917	0.735
0.70	62.305	0.561	42.406	0.756
0.80	61.438	0.573	44.273	0.758
0.90	8.856	0.102	45.38	0.744
1.00	7.832	0.024	7.837	0.022

Podem veure que SARSA és molt més sensible al α que Q-learning, ja que aquest darrer es manté igual al llarg de totes les combinacions.

Per a valors molt grans de α ambdós tenen resultats molt pobres, sobretot quan son molt propers a 1. Això té sentit perquè significa que per a cada actualització de la política s'està corregint un 100% de l'error, es a dir, s'estàn fent salts molt grans i no s'arriba a la solució òptima (s'arriba a un màxim local enlloc d'un màxim global).

3.2 Algorismes de cerca

3.2.1 Genètic

Per a l'algorisme Genètic tenim els següents paràmetres:

- *population_size* = 100: Nombre total d'individus a la població per a cada generació.
- *selection_pressure* = 0.50: Percentatge de la població que es selecciona per a generar la pròxima generació, la resta es descarten.
- *mutation_rate* = 0.08: Probabilitat de mutar cada un dels gens de cada individu nou generat.
- *culling_rate* = 0.01: Percentatge de la població que passa directament a la següent generació (també conegut com a elitisme).

Amb aquests valors per defecte dels paràmetres obtenim els següents resultats que ens serviran per a comparar amb el pròxim apartat:

Genètic	
steps	sr
40.5680	0.6920

	Genètic	
<i>population_size</i>	steps	sr
1	5.4120	0.0240
10	27.7020	0.1930
100	43.0160	0.7150
1000	40.1770	0.7340
10000	41.9850	0.7250

Hi ha una tendència molt clara amb la quantitat d'individus dintre de la població: quants més n'hi ha millor és el resultat.

Els resultats es saturen i ja no milloren quan s'atraquen als 100 individus. Al ser un entorn molt petit i limitat, tenir una població molt gran no proporciona molta millora. Potser que per a entorns on els individus tenguin més gens una població més gran permeti una població amb més varietat i en conseqüència generi millors resultats.

	Genètic	
<i>selection_pressure</i>	steps	sr
0.10	44.8740	0.7330
0.20	45.5660	0.7360
0.30	41.9680	0.7250
0.40	41.2320	0.7200
0.50	41.9620	0.7250
0.60	39.4190	0.7040
0.70	41.6150	0.7000
0.80	39.3180	0.7020
0.90	38.7690	0.5880
1.00	41.8970	0.7410

Resultats bàsicament idèntics. Només hi ha un *Survival Rate* per davall dels altres que probablement sigui degut a la inicialització de la llavor del generador de nombres aleatoris.

Al igual que la mida de la població, segurament amb un problema més complex hi hauria una variació major.

	Genètic	
<i>mutation_rate</i>	steps	sr
0.00	42.5690	0.7660
0.10	41.9430	0.7370
0.20	41.2760	0.7230
0.30	41.9580	0.7210
0.40	37.6350	0.6730
0.50	41.7470	0.5280
0.60	34.6640	0.4390
0.70	41.5350	0.5550
0.80	29.5650	0.3280
0.90	32.7790	0.4000
1.00	23.2970	0.2750

Resultats molt millors per a un *mutation_rate* menor. Té sentit perquè com més gran és aquest valor més s'atraca a ser una cerca aleatòria.

	Genètic	
<i>culling_rate</i>	steps	sr
0.00	41.7680	0.7070
0.10	38.1680	0.7420
0.20	44.6360	0.7440
0.30	41.5580	0.7150
0.40	42.8560	0.7330
0.50	41.6510	0.7350
0.60	39.6660	0.7160
0.70	41.0450	0.7300
0.80	40.8990	0.7040
0.90	45.2610	0.7380
1.00	41.0240	0.6990

Resultats bàsicament constants. Al igual que la mida de la població i la pressió de selecció, aquest és un entorn massa senzill i amb un altre una mica més complex potser es vegessin els canvis.

3.2.2 Programació dinàmica

Per a l'algorisme de Programació Dinàmica només tenim el paràmetre $\gamma = 0.95$ és el factor de descompte per a la recompensa esperada per a cada passa del mateix episodi.

Amb aquests valors per defecte dels paràmetres obtenim els següents resultats que ens serviran per a comparar amb el pròxim apartat:

Prog. Dinàmica	
steps	sr
39.7750	0.7340

	Prog. Dinàmica	
γ	steps	sr
0.10	27.4400	0.4560
0.20	27.7030	0.4160
0.30	27.0910	0.4560
0.40	28.0500	0.4560
0.50	28.3110	0.4450
0.60	27.0930	0.4220
0.70	27.2700	0.4430
0.80	27.7850	0.4250
0.90	39.7830	0.7520
1.00	40.0280	0.7500


Els resultats es mantenen constants del 0.10 fins al 0.80 i després milloren bastant i es saturen a partir del 0.90. Un γ major té sentit perquè al estar explorant tots els estats possibles ens interessa mantenir tota la informació (sabem que el resultat és correcte perquè els hem explorat tots).

Anàlisi rendiment

Com que els algorismes d'aprenentatge necessiten una quantitat molt elevada d'episodis per a la fase d'entrenament i els de cerca en necessiten molt menys (en l'ordre de 1000x menys) es separen aquestes dues categories amb dues gràfiques diferents.

A més, els algorismes d'aprenentatge al necessitar moltes iteracions, cal realitzar qualche tipus d'agregació dels valors per a poder obtenir una senyal interpretable. Hem decidit utilitzar una mitjana mòbil dels darrers 1000 valors. En els casos on s'utilitzi s'indica al títol del gràfic amb l'acrònim SMA (*Simple Moving Average*) seguit del valor de la finestra.


Primer de tot, anem a analitzar l'evolució del rendiment de la política durant el procés d'entrenament. Per fer-ho, utilitzam el *Success Rate* que és el nombre promig de vegades que s'arriba al destí al llarg d'uns quants episodis. Pels algorismes d'aprenentatge s'utilitza el promig de vegades que s'ha arribat al destí dintre la finestra i pels algorismes de cerca s'avalua la política 100 vegades després de cada iteració d'entrenament (ambdós utilitzen una política ϵ -greedy; excepte per l'algorisme genètic).




Podem veure com tots els algorismes comencen amb un *Success Rate* molt baix degut a que la seva política és completament aleatòria i no aconsegueixen arribar al destí, milloren molt ràpidament i arriben a un punt de saturació a partir d'un cert nombre d'iteracions a partir del qual ja no milloren més. En el cas particular de la programació dinàmica inclús es podria especular que la millora és lineal, però tampoc ho podem afirmar perquè la quantitat de punts de dades és molt baix.

A partir de les proves que hem anat realitzant durant el desenvolupament sabem que el punt de saturació de l'algorisme Monte Carlo oscila entre els 0.10 i 0.70 de *Success*



Rate. Això depèn de la inicialització de la llavor del generador de nombres aleatoris i no sabem molt bé com o si es pot evitar. Si realitzam l'entrenament de l'algorisme 5 vegades obtenim el següent resultat:



Una altra mètrica a mirar és el temps de cada iteració del bucle d'entrenament, que està directament relacionat amb el nombre de passes que es realitzen a cada episodi. Com que al principi de l'entrenament la política és aleatòria els episodis acaben molt aviat perquè quan es cau a un forat aquest acaba. Així com l'algorisme millora la política i s'evita caure als forats es permeten fer més passes i allargar l'episodi. Per tant, aquestes dues mètriques també estan vinculades al *Success Rate* que hem vist abans.




Pel cas de la Programació Dinàmica el temps d'execució de cada iteració d'entrenament és despreciable i es manté constant a uns $65\mu s$. Això és degut a que aquest algorisme no crida a l'entorn de *Frozen Lake* de Gymnasium ja que només necessita la matriu de probabilitats de transició per a cada estat.



Anàlisi polítiques

A continuació es mostren les polítiques per a cada un dels algorismes representades amb dues gràfiques. El gràfic de l'esquerra mostra la taula Q. El color de cada cel·la representa el valor de la recompensa esperada per a aquell estat (blau més fort implica una recompensa major) i les fletxes representen les accions amb la seva llargària proporcional al seu valor (una fletxa més llarga té una recompensa esperada més alta que d'una de petita). El gràfic de la dreta mostra el mateix però només amb la fletxa de més valor per a poder distingir quina és la millor opció.



A primera vista, el que ressalta més és la distribució dels valors sobre el mapa.

- Monte Carlo sembla prioritzar un camí molt més que l'altre (primer moviment per avall enlloc de la dreta).
- SARSA té la mateix preferència que Monte Carlo però menys exagerada.
- Q-learning té les recompenses molt repartides, producte de la seva naturalesa optimista.
- A Programació Dinàmica les recompenses són més altes a prop del destí i decreixen ràpidament a mesura que s'allunya.

El que pot semblar poc intuïtiu és la millor acció que trien els algorismes. Per exemple, no n'hi ha cap que per a l'estat anterior del final (el que està marcat amb més valor; abaix a la dreta) indiqui l'acció que duu directament cap al destí com a la millor.

Això és degut a que hi ha major probabilitat de lliscar que fer l'acció escollida:

$$p(\text{dreta}) = p(\text{amunt}) = p(\text{avall}) = \frac{1}{3} \implies p(\text{amunt} \cup \text{avall}) = \frac{2}{3} > \frac{1}{3} = p(\text{dreta})$$


Exactament el mateix passa amb els estats adjacents a forats, ja que alguns models trien l'opció que duu directament al forat com a la millor.

Per a profunditzar un poc més sobre aquest fenomen anem a analitzar la quantitat de vegades que l'algorisme tria una determinada acció durant la fase de l'entrenament (només es mostren els algorismes d'aprenentatge perquè dels altres és impossible saber aquesta dada).




Es veu clarament que per a tots els algorismes hi ha una preferència sobre l'acció *left* seguit de l'acció *up*. Si ho raonem, té sentit que sigui així perquè l'episodi sempre comença dalt de tot a l'esquerra i tots els forats estan abaix a la dreta i com que sortir-se del tauler no provoca el fi de l'episodi és preferible anar cap a defora (*left* o *up*) i així evitar caure a un forat en el cas de que es llisqui.

El darrer algorisme, el Genètic, al calcular directament la política i no calcular els valors d'estat-acció només es poden mostrar les fletxes (accions) i, per tant, no es pot fer un anàlisi tan detallat. Però és interessant veure com, sense calcular els valors d'estat-acció i només utilitzant la "força bruta", s'arriba a una política pràcticament idèntica a molts dels altres algorismes.



També pot ser interessant analitzar la quantitat de passes realitzades per a cada algorisme al llarg de 100 episodis. Es mostren dues versions per tal de mostrar com afecta la qualitat de la política amb el nombre de passes per episodi. El gràfic de l'esquerra pertany a una execució on totes les polítiques aconseguirien un *Success Rate* del 0.70, i a la dreta on Monte Carlo només ha aconseguit un 0.10 i la resta es mantenen igual.



Es veu clarament que una millor política implica més passes (per les mateixes raons comentades a l'apartat d'Anàlisi del rendiment). Curiosament, SARSA i Q-learning semblen generar unes polítiques lleugerament més conservadores (més passes significa que s'ha anat més alerta a caure).

Conclusió

L'entorn *Frozen Lake* de Gymnasium tot i ser un entorn molt simple hem vist com el problema es complica molt quan s'activa l'opció *slippery* (passam d'un entorn completament determinista a un que no ho és). Hem posat a prova tots els algorismes vists a teoria, hem pogut veure les forces i febleses de cada un d'ells i l'importància de cada un dels seus paràmetres.

En particular hem vist que Monte Carlo és molt inconsistent amb els resultats que proporciona. Potser això es pugui solucionar amb diferents combinacions dels paràmetres però no hem tengut el temps per a investigar-ho.

Hem pogut profunditzar bastant en el funcionament dels algorismes i hem vist el gran impacte de la decisió originalment “preventiva” del *tie-break* aleatori a l'anàlisi dels paràmetres, cosa que no ens esperavem.

En quant a la Programació Dinàmica, tot i ser un algorisme molt senzill d'implementar i que proporciona bons resultats, té l'inconvenient de necessitar tota la informació de l'entorn per a funcionar, si bé Gymnasium proporciona el model de l'entorn, això no sempre és possible en problemes reals.

Interessant, també, veure com les polítiques resultants poden ser contraintuïtives (considerar anar directament cap a un forat com la millor opció) i com hi ha accions molt més preferibles que altres.

Com a opinió personal, podem dir que és un projecte que ha posat a prova el que sabem i ens ha forçat a repassar i expandir conceptes que hem vists a teoria, cosa molt important a l'hora d'assolir coneixements. A la part d'anàlisi haguéssim pogut profunditzar o complicar més però amb el que hem fet ja hem anat molt justs de temps.

Intel·ligències Artificials Generatives

Al llarg del desenvolupament del projecte hem emprat les següents intel·ligències artificials generatives:

- ChatGPT-5.1
 - Validació i correcció dels algorismes implementats amb Python
 - Recomanació de la configuració de paràmetres per a diferents algorismes
 - Correcció de la notació matemàtica utilitzada a la memòria
- Grok 4.1:
 - Validació i correcció dels algorismes implementats amb Python
 - Recomanació de la configuració de paràmetres per a diferents algorismes
 - Correcció d'errors i millores de la notació matemàtica utilitzada a la memòria.
- Perplexity (ChatGPT-5.1, Claude Sonnet 4.5 o Sonar):
 - Cerca de documentació i exemples de Python, Numpy i Matplotlib

Pràctica II

Intel·ligència Artificial

Aprenentatge per reforç

Serafi Nebot Ginard
Jaume Galmés Ramis

Grau d'Enginyeria Informàtica
Curs 2025/2026